

MAP 556 - TP 1 - 19 et 21 septembre 2018

Simulation de variables aléatoires et théorèmes limites fondamentaux

Quelques lignes guide pour l'usage de Python:

- Un script `python` est un fichier texte avec l'extension `.py`. Un tel script peut être modifié avec n'importe quel éditeur de texte, et exécuté à partir d'une console Python. Si Python n'est pas déjà installé sur votre machine, nous conseillons de télécharger la distribution *Anaconda*

<https://www.anaconda.com/download/>

qui installe: une version de Python, les bibliothèques de base (`numpy`, `scipy`, `matplotlib`) et l'environnement de développement `spyder`.

- Rappel: dans Python 2.x, il faudra s'interdire l'utilisation de caractères accentués dans un script (même dans les commentaires!).
- On écrira un fichier `.py` par question, en donnant au fichier un nom explicite, comme par exemple `MAP556_TP1_Exo1_1.py`
- Nous utiliserons la programmation matricielle, en travaillant avec les variables de la bibliothèque `numpy`, en évitant autant que possible les boucles. Cela permet d'avoir un gain en temps de calcul dans la plus part de nos applications.

EXERCICE 1 - Simulation de variables aléatoires dans Python. Loi des grands nombres.

Soit $(X_i)_{i \geq 1}$ une suite de variables aléatoires i.i.d. telles que $\mathbb{E}[|X_1|] < \infty$. La loi forte des grands nombres affirme que la suite des *moyennes empiriques*

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

converge presque sûrement vers $\mathbb{E}[X_1]$ lorsque $n \rightarrow \infty$.

1. En complétant le fichier `MAP556_PC1_Exo1_1.py`, simuler un grand nombre N de variables aléatoires uniformes sur $[0, 1]$ indépendantes et représenter graphiquement la suite des moyennes empiriques \bar{X}_n pour n allant de 1 à N . On pourra utiliser la fonction `numpy.random.rand` pour obtenir les tirages de la loi uniforme et la fonction `numpy.cumsum` pour calculer la moyenne empirique cumulée jusqu'à n .
2. La loi de Cauchy de paramètre $a > 0$ est la loi sur \mathbb{R} de densité

$$f(x) = \frac{a}{\pi(a^2 + x^2)}.$$

- (a) Soit $F(x) = \int_{-\infty}^x f(y)dy$ sa fonction de répartition. Soit U une v.a. de loi uniforme sur $[0, 1]$. Quelle est la loi de $F^{-1}(U)$?

- (b) Fichier MAP556_PC1_Exo1_2.py. En remarquant que $F(x) = \frac{1}{\pi} \arctan(\frac{x}{a}) + \frac{1}{2}$, générer un grand nombre N de variables aléatoires indépendantes de loi de Cauchy de paramètre $a = 1$, toujours en utilisant la fonction `numpy.random.rand`. Représenter graphiquement la suite des moyennes empiriques \bar{X}_n pour n allant de 1 à N . Qu'observez-vous?

EXERCICE 2 - Théoreme central limite. Intervalles de confiance. Soit $(X_i)_{i \geq 1}$ une suite de variables aléatoires i.i.d. telles que $\mathbb{E}[X_1^2] < \infty$, et $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ la suite de leurs moyennes empiriques. Le théoreme central limite affirme que la suite des erreurs renormalisées

$$e_n = \frac{\sqrt{n}}{\sqrt{\text{Var}(X_1)}} (\bar{X}_n - \mathbb{E}[X_1])$$

converge en loi vers une gaussienne $\mathcal{N}(0, 1)$ lorsque $n \rightarrow \infty$.

1. (a) Fichier MAP556_PC1_Exo2_1_a.py. On considère une suite iid de v.a. exponentielles de paramètre 2. Pour N fixé, obtenir un échantillon de M valeurs de la moyenne empirique $(\bar{X}_N^j)_{j=1, \dots, M}$. Tracer l'histogramme des valeurs correspondantes de l'erreur normalisée

$$e_N^j = \sqrt{\frac{N}{\text{Var}(X_1)}} (\bar{X}_N^j - \mathbb{E}[X_1]), \quad j = 1, \dots, M$$

et le comparer avec la densité gaussienne centrée réduite.

- (b) Fichier MAP556_PC1_Exo2_1_b.py. Afin d'illustrer la différence entre convergence en loi et convergence presque sûre, tracer une réalisation de la suite e_n pour n variant de 1 à N . Qu'observez-vous?
2. *Intervalles de confiance.* A différence de l'exemple précédent, en pratique on ne connaît pas la valeur $\text{Var}(X_1)$. On peut cependant l'estimer à partir des mêmes simulations, en utilisant l'estimateur de la variance $\sigma_n^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X}_n)^2$.

- (a) Quel resultat permet d'affirmer que la suite

$$\frac{\sqrt{n}}{\sigma_n} (\bar{X}_n - \mathbb{E}[X_1])$$

converge en loi vers $\mathcal{N}(0, 1)$?

- (b) En définissant l'intervalle (aléatoire) $I_n^\delta = \left[\bar{X}_n - \delta \frac{\sigma_n}{\sqrt{n}}, \bar{X}_n + \delta \frac{\sigma_n}{\sqrt{n}} \right]$, $\delta > 0$, la question précédente entraîne

$$\mathbb{P}(\mathbb{E}[X_1] \in I_n^\delta) = \mathbb{P}\left(\frac{\sqrt{n}}{\sigma_n} |\bar{X}_n - \mathbb{E}[X_1]| \leq \delta\right) \longrightarrow \mathbb{P}(|\mathcal{N}(0, 1)| \leq \delta) = 2 \int_0^\delta \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx$$

lorsque $n \rightarrow \infty$. Pour $\delta = 1.96$, le dernier terme à droite vaut approximativement 0.95, ce qui permet d'identifier $I_n^{1.96}$ comme étant l'intervalle de confiance *asymptotique* à 95% pour l'espérance $\mathbb{E}[X_1]$.

Fichier MAP556_PC1_Exo2_2.py. Fournir une estimation de l'espérance de v.a. uniformes sur $[0, 1]$ avec son intervalle de confiance à 95% donné par le TCL.